

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
(Universidad del Perú, DECANA DE AMÉRICA)
FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA DE SOFTWARE

“Solución integral de BI para AndesMarket S.A.C.”

Curso:



Inteligencia de Negocios

Modalidad:

Individual

Estudiante:

Bryan Anghelo Silva Burga

Código: [Completar]

Docente:

Mg. Juan Gamarra Moreno

Lima - Perú

2026

2. Resumen ejecutivo

El proyecto desarrolla una solución integral de Inteligencia de Negocios para AndesMarket S.A.C., empresa ficticia de retail omnicanal en Perú. La solución cubre generación de datos sintéticos, limpieza y ETL, construcción de datamart, visualización en Power BI y modelos de minería de datos: clasificación, segmentación, asociación y regresión.

La base analítica se construyó con datos sintéticos reproducibles, generados con semilla fija 42. Los datos crudos incorporan problemas de calidad controlados como fechas mixtas, nulos, duplicados, errores de categoría, outliers y claves huérfanas. El ETL corrige estos problemas y exporta tablas limpias en `data/processed/`.

Los principales resultados son:

- Datamart con esquema estrella a nivel de línea de venta.
- Tablero Power BI con páginas de ventas, categorías, región, tiempo, abandono, segmentación, canasta de mercado y pronóstico.
- Modelo de abandono con Random Forest como uno de los mejores modelos, con recall alto para detectar clientes en riesgo.
- Segmentación RFM con cuatro segmentos: Campeones, Leales de valor, Ocasionales y En riesgo.
- Reglas de canasta de mercado con lift positivo, destacando combinaciones como Congelados -> Carnes, Panadería -> Lácteos y Snacks -> Bebidas.
- Pronóstico de ventas diarias con Regresión Lineal como mejor modelo, MAPE aproximado de 7.48% y R² de 0.931.

3. Empresa ficticia, problemática y preguntas de negocio

AndesMarket S.A.C. es una cadena ficticia de supermercados con tiendas físicas y canal online. Cuenta con un programa de fidelización llamado AndesPlus. La gerencia busca transformar datos transaccionales dispersos en información confiable para tomar decisiones sobre ventas, clientes, promociones e inventario.

Problemática:

- Datos operativos dispersos.
- Fechas y categorías inconsistentes.
- Registros duplicados y valores faltantes.
- Ausencia de un datamart único.

- Falta de tableros y modelos predictivos para apoyar decisiones.

Preguntas de negocio:

- Como evolucionan ventas y margen por categoria, tienda, canal y periodo?
- Que clientes tienen mayor probabilidad de abandono?
- Que segmentos de clientes existen y que estrategia aplicar a cada uno?
- Que categorias se compran juntas?
- Cual sera la venta esperada para planificar inventario y campanas?

4. Generacion de datos sinteticos

La generacion se realizo en notebooks/00_generacion_datos.ipynb. Se usaron pandas, numpy y faker con semilla fija 42.

Tablas generadas:

- `dim_cliente`: clientes sinteticos, sexo, fecha de nacimiento, distrito, fecha de alta y segmento AndesPlus.
- `dim_producto`: productos, categoria, subcategoria, marca, precio y costo.
- `dim_tienda`: tiendas fisicas y canal online.
- `dim_tiempo`: calendario de dos anos.
- `dim_promocion`: promociones con fechas y descuentos.
- `fact_ventas`: ventas a nivel de linea de boleta.

Reglas de realismo:

- Estacionalidad en julio y diciembre.
- Concentracion tipo Pareto en productos y clientes.
- Precios derivados de precio lista con variacion controlada.
- Promociones aplicadas segun vigencia.
- Afinidades de canasta entre categorias.
- Clientes con comportamiento de abandono.

Problemas de calidad introducidos:

- Fechas en formatos mixtos.
- Valores faltantes en descuento, distrito y categoria.
- Duplicados en ventas.
- Texto inconsistente en categorias.
- Errores de tipeo.
- Outliers en cantidad y precio.
- Claves huérfanas de producto.

5. Parte 1 - Datamart y ETL

El ETL se implemento en notebooks/01_datamart_etl.ipynb.

Grano:

- Una línea de venta, es decir, un producto dentro de una boleta.

Modelo dimensional:

- fact_ventas
- dim_cliente
- dim_producto
- dim_tienda
- dim_tiempo
- dim_promocion

Tratamientos aplicados:

- Parseo robusto de fechas.
- Homologación de categorías.
- Imputación de nulos.
- Eliminación de duplicados.

- Validacion de claves huérfanas.
- Tratamiento de outliers.
- Calculo de importe, costo_total y margen.

Resultado de calidad posterior:

- fact_ventas: sin nulos, sin duplicados y sin claves huérfanas.
- Dimensiones limpias y listas para Power BI.

6. Parte 2 - Visualizacion

La visualizacion en Python se desarrollo en notebooks/02_visualizacion.ipynb. Se exportaron graficos a informe/img/ e insights a informe/insights_visualizacion.md.

Hallazgos:

- La categoria con mayor venta es Bebidas.
- El mes de mayor venta es 2025-07.
- El 20% superior de productos concentra una parte importante de ventas.
- Lima es la region con mayor aporte.
- El canal online tiene participacion menor frente al canal fisico.
- El margen bruto global muestra que no todas las decisiones deben basarse solo en volumen.

En Power BI se construyo un tablero con paginas de resumen ejecutivo, categorias/productos, canal/region y tendencia temporal.

7. Parte 3 - Clasificacion

La clasificacion se desarrollo en notebooks/03_clasificacion.ipynb.

Objetivo:

- Predecir abandono de clientes.

Definicion:

- Se uso una ventana temporal para evitar fuga de informacion. Las variables se calcularon con informacion historica y la etiqueta de abandono se definio segun ausencia de compra en el periodo futuro.

Modelos comparados:

- Regresion Logistica.
- Arbol de Decision.
- Random Forest.

Metricas principales:

- Accuracy.
- Precision.
- Recall.
- F1.
- ROC-AUC.

Salida para Power BI:

- data/processed/predicciones_abandono.csv
- data/processed/metricas_clasificacion.csv
- data/processed/importancia_variables_clasificacion.csv

Acciones recomendadas:

- Priorizar clientes de riesgo alto y alto monto historico.
- Aplicar descuentos selectivos.
- Contactar clientes con alta recencia y baja frecuencia.
- Adaptar acciones por segmento AndesPlus.

8. Parte 4 - Segmentacion

La segmentacion se desarrollo en notebooks/04_segmentacion.ipynb.

Variables RFM:

- Recencia.
- Frecuencia.

- Monto.

Metodologia:

- Transformacion logaritmica para reducir efecto de outliers.
- Escalamiento con standardScaler.
- Evaluacion de k con codo y silueta.
- K-Means con $k = 4$.

Segmentos:

- Campeones.
- Leales de valor.
- Ocasionales.
- En riesgo.

Salida para Power BI:

- data/processed/segmentos_clientes.csv
- data/processed/perfil_segmentos.csv
- data/processed/evaluacion_k_segmentacion.csv

Estrategias:

- Campeones: beneficios exclusivos.
- Leales de valor: venta cruzada y paquetes premium.
- Ocasionales: campanas de recurrencia.
- En riesgo: recuperacion con ofertas personalizadas.

9. Parte 5 - Asociacion

La asociacion se desarrollo en notebooks/05_asociacion.ipynb.

Objetivo:

- Identificar categorias que se compran juntas y proponer promociones cruzadas.

Método:

- Transacciones por boleta.
- One-hot encoding.
- Algoritmo Apriori.
- Reglas con soporte, confianza y lift.
- Filtro de reglas con $\text{lift} > 1$.

Reglas destacadas:

- Congelados -> Carnes.
- Carnes -> Congelados.
- Panadería -> Lácteos.
- Lácteos -> Panadería.
- Abarrotes -> Limpieza.
- Snacks -> Bebidas.

Salida para Power BI:

- `data/processed/reglas_asociacion.csv`
- `data/processed/itemsets_frecuentes.csv`
- `data/processed/resumen_transacciones_asociacion.csv`

Acciones:

- Promociones cruzadas.
- Exhibición conjunta.
- Cupones por compra complementaria.
- Recomendaciones online.

10. Parte 6 - Regresión

La regresión se desarrolló en `notebooks/06_regresion.ipynb`.

Objetivo:

- Pronosticar ventas diarias agregadas.

Features:

- Variables temporales.
- Indicador de meses altos.
- Promociones.
- Rezagos.
- Promedios móviles.

Validación:

- División temporal 80% entrenamiento y 20% prueba.

Modelos comparados:

- Regresión Lineal.
- Random Forest.
- Gradient Boosting.

Mejor resultado:

- Regresión Lineal.
- MAE: 246.01.
- RMSE: 316.41.
- MAPE: 7.48%.
- R²: 0.931.

Salida para Power BI:

- data/processed/pronostico_ventas.csv
- data/processed/metricas_regresion.csv

Uso de negocio:

- Planificación de inventario.

- Programación de campañas.
- Seguimiento de desviaciones entre real y pronóstico.

11. Power BI

Archivo:

- `powerbi/AndesMarket.pbix`

Páginas implementadas:

1. Resumen Ejecutivo.
1. Categorías y Productos.
1. Canal y Región.
1. Tendencia Temporal.
1. Riesgo de abandono.
1. Segmentación de clientes.
1. Canasta de mercado.
1. Pronóstico de demanda.

12. Uso de IA, ética e integridad

Se usó IA como apoyo para estructurar el proyecto, validar enfoques, generar código base y documentar decisiones. Los prompts relevantes se registraron en `prompts/registro_prompts.md`.

El estudiante revisó, ejecutó y ajustó los resultados. Los datos son sintéticos y no corresponden a personas ni empresas reales. La solución evita uso de datos personales reales y permite reflexionar sobre privacidad, sesgo y uso responsable de modelos predictivos.

Consideraciones éticas:

- No usar datos reales de clientes.
- Evitar decisiones automáticas sin revisión humana.
- Usar modelos como apoyo y no como única fuente de decisión.
- Revisar sesgos por segmento, canal o ubicación.

- Informar limitaciones de datos sintéticos y modelos.

13. Conclusiones

- Se construyó una solución BI integral y reproducible para AndesMarket.
- El datamart permite analizar ventas, margen, categorías, tiendas, canal y tiempo.
- Los modelos de minería aportan valor adicional para retención, segmentación, promociones cruzadas y pronóstico.
- Power BI consolida la información en páginas orientadas a decisión gerencial.
- La solución es extensible: podría incorporar datos reales anonimizados, más histórico y automatización de refresh.

14. Recomendaciones

- Revisar semanalmente clientes en riesgo alto.
- Usar segmentos RFM para diseñar campañas diferenciadas.
- Aplicar reglas de asociación en promociones cruzadas y ubicación de productos.
- Monitorear error del pronóstico y recalibrar modelos con nuevos datos.
- Mantener un proceso ETL reproducible y documentado.